

ALMA MATER STUDIORUM · UNIVERSITÀ DI BOLOGNA

SCUOLA DI SCIENZE
Corso di Laurea in Informatica

**Choreia: A Static Analyzer
to generate Choreography Automata
from Go source code**

Relatore:
Chiar.mo Prof.
Ivan Lanese

Presentata da:
Enea Guidi

Sessione III
Anno Accademico 2020/2021

*Agli amici che ho conosciuto e che
mi hanno accompagnato in questo viaggio*

Sommario

Le Choreographies sono un paradigma emergente per la descrizione dei sistemi concorrenti che sta prendendo piede negli ultimi anni. Lo scopo principale è quello di fornire al programmatore uno strumento il quale permetta di capire in maniera immediata la *coreografia* dei partecipanti nel sistema e come questi interagiscano tra loro. Partendo dai singoli partecipanti, e le loro Choreographies *locali*, è possibile ricomporre in maniera bottom-up l'intera Choreography *globale* del sistema. Un ulteriore vantaggio delle Choreographies è che, quando rispettano alcune proprietà definite, permettono di fare assunzioni sull'assenza di tipici problemi di concorrenza quali Deadlocks, Liveness e Race Conditions. Esistono vari modelli formali di Choreographies, questa tesi tratta nello specifico i *Choreography Automata*, basati su *Finite State Automata* (FSA). In questa tesi viene presentato Choreia: un tool di analisi statica che, partendo da un codice sorgente Go, ricava il Choreography Automata del sistema concorrente in maniera bottom-up.

Indice

1	Introduzione	2
2	Nozioni preliminari e notazione	3
2.1	FSA non deterministici e deterministici	3
2.1.1	Minimizzazione	5
2.1.2	Esempi	6
2.2	Choreography Automata	7
2.2.1	CFSM e Local Views	8
3	Adattazioni e modifiche	10
4	Tecnologie utilizzate	11
5	Descrizione del tool	12
6	Conclusioni e lavori futuri	13

Capitolo 1

Introduzione

Negli ultimi anni si è visto un interesse sempre più pronunciato verso lo sviluppo di sistemi concorrenti e distribuiti, questo si riflette nella progettazione a microservizi o in linguaggi di programmazione più recenti come Go, Rust o C++ 20 i quali implementano tutti, in forme disparate, un approccio alla concorrenza facilitato e univoco evitando la complessità e frammentazione che può derivare dall'utilizzo di librerie esterne e non standardizzate.

Prendendo per esempio Go, talvolta chiamato anche golang, un linguaggio di programmazione creato nel 2009 da Robert Griesemer, Rob Pike e Ken Thompson, che negli anni successivi prende una forte trazione, fino a essere supportato da Google, soprattutto nel settore del web-development e system programming. Alcuni dei fattori da successo sono una compilazione ed esecuzione veloce, una grammatica semplice e snella e un approccio *built-in* alla concorrenza con tipi e primitive fornite direttamente dalla standard library. Quest'ultima infatti fornisce un solo tipo di dato *chan* che può essere *buffered* o *unbuffered*, la comunicazione che avviene su questi canali è rispettivamente asincrona e sincrona.

Parallelamente a questo rinnovato interesse verso la programmazione concorrente e distribuita nasce l'esigenza di formalizzare dei modelli teorici che possano supportare la progettazione, gestione e manutenzione di sistemi concorrenti. Uno di questi modelli sono le *Choreographies*, le quali facilitano la rappresentazione e descrizione di sistemi concorrenti in cui i singoli *attori* comunicano tra di loro. Un aspetto distintivo delle *Choreographies* è la coesistenza di due *view*:

- Vista **globale**: descrive la coordinazione necessaria tra i componenti di un sistema
- Vista **locale**: descrive il comportamento di un singolo componente *in isolamento*

L'obiettivo di questa tesi è quello di progettare e implementare un tool che permetta, preso un sorgente Go e per mezzo di analisi statica, di estrarre un Choreography Automata, ovvero un automa a stati finiti che rappresenta la Choreography in modo grafico, più chiaro e immediato rispetto alla lettura del codice sorgente.

Capitolo 2

Nozioni preliminari e notazione

2.1 FSA non deterministici e deterministici

Prima di introdurre le Choreography e i Choreographies Automata è necessario fare un breve richiamo di alcune nozioni fondamentali quali la nozione di Automa a Stati Finiti (FSA) e alcune operazioni possibili sugli stessi. Gli automi a stati finiti sono la descrizione di un sistema dinamico che si evolve nel tempo, esiste un parallelo tra gli automi e i calcolatori moderni, per esempio il flusso d'esecuzione di un programma può essere rappresentato attraverso un automa (come vedremo più avanti). Alcune applicazioni pratiche di questi automi possono essere, per esempio, regular expression (RegEx o RegExp), lexer e parser ma possono anche essere impiegati, come vedremo in questa tesi, anche nel campo dei sistemi concorrenti.

Si noti che sebbene per gli scopi di questa tesi gli automi a stati finiti sono dei costrutti sufficientemente potenti esistono tuttavia altre classi di automi, espressivamente più potenti, ai quali corrispondo altrettante classi di linguaggi (si veda, per esempio, gli automi a pila) tuttavia gli automi appartenenti a questa classe sono tra i più semplici e immediati e forniscono una sufficiente espressività per gli scopi di questa tesi.

Definition 2.1 (Finite State Automata) *Un automa a stati finiti (FSA) è una tupla $A = \langle \mathcal{S}, s_0, \mathcal{F}, \mathcal{L}, \delta \rangle$ dove:*

- \mathcal{S} è un insieme finito di stati
- $s_0 \in \mathcal{S}$ è lo stato iniziale dell'automa
- \mathcal{F} è l'insieme degli stati finali (o di accettazione)
- \mathcal{L} è l'alfabeto finito, talvolta detto anche insieme di label ($\epsilon \notin \mathcal{L}$)
- $\delta : \mathcal{S} \times (L \cup \{\epsilon\}) \rightarrow \mathcal{P}(\mathcal{S})$ è la funzione di transizione (ϵ denota la stringa vuota)

Remark 2.1.1 *Tipicamente è solito trovare anche una definizione alternativa ma equivalente in cui l'insieme degli stati di terminazione \mathcal{F} non è presente, in tal caso assumiamo che ogni $s \in \mathcal{S}$ sia uno stato di accettazione.*

Remark 2.1.2 *Va notato anche che questa definizione coincide con quella di automa a stati finiti non deterministico, solitamente indicato in letteratura con la sigla NFA (Non Deterministic Finite Automata) e distinto dalla nozione di DFA (Deterministic Finite Automata).*

Definition 2.2 (Deterministic Finite Automata) *Un automa a stati finiti deterministico è una tupla $D = \langle \mathcal{S}, s_0, \mathcal{F}, \mathcal{L}, \delta \rangle$ dove $\delta : \mathcal{S} \times L \rightarrow \mathcal{S}$*

Le varianti deterministiche si distinguono dalle loro controparti non deterministiche dal fatto che non ammettono né l'utilizzo di ϵ transizioni, né l'utilizzo di transizioni *uscenti*, dallo stesso stato, con la medesima etichetta. Sebbene queste due varianti siano tra loro equivalenti, l'utilizzo di una variante rispetto all'altra può essere determinato da fattori come: necessità di una maggiore elasticità (gli NFA sono meno stringenti rispetto ai DFA) o di una migliore chiarezza (i DFA sono più immediati e semplici).

In ogni caso è sempre possibile, dato un NFA qualunque, ottenere un DFA ad esso equivalente. L'algoritmo che permette di fare questa trasformazione fa uso estensivo di ϵ closure e della funzione *mossa* che andremo a definire di seguito:

Definition 2.3 (ϵ closure) *Fissato un NFA $N = \langle \mathcal{S}, s_0, \mathcal{F}, \mathcal{L}, \delta \rangle$ ed uno stato $s \in \mathcal{S}$ si dice ϵ closure di s , indicata con $\epsilon\text{-clos}(s)$, il più piccolo $\mathcal{R} \subseteq \mathcal{S}$ tale che:*

- $s \in \epsilon\text{-clos}(s)$
- se $x \in \epsilon\text{-clos}(s)$ allora $\delta(x, \epsilon) \subseteq \epsilon\text{-clos}(s)$

Remark 2.3.1 *Se \mathcal{X} è un insieme di stati definiamo $\epsilon\text{-clos}(\mathcal{X})$ come $\bigcup_{x \in \mathcal{X}} \epsilon\text{-clos}(x)$.*

Definition 2.4 (Mossa) *Dato un insieme di stati $\mathcal{X} \subseteq \mathcal{S}$ e un simbolo $\alpha \in \mathcal{L}$ definiamo la funzione *mossa*: $\mathcal{P}(\mathcal{S}) \times \mathcal{L} \rightarrow \mathcal{P}(\mathcal{S})$ tale che: $\text{mossa}(\mathcal{X}, \alpha) = \bigcup_{x \in \mathcal{X}} (\delta(x, \alpha))$, , ovvero l'insieme di stati raggiungibili da un dato insieme di stati di partenza, leggendo in input α .*

L'algoritmo che permette di ricavare un DFA da un qualsiasi NFA è il seguente:

Algorithm 2.1 Costruzione per sottoinsiemi

```

 $x \leftarrow \epsilon\text{-clos}(s_0)$  ▷ Lo stato iniziale del DFA
 $\mathcal{T} \leftarrow \{x\}$  ▷ Un insieme di  $\epsilon\text{-clos}$ 
while  $\exists t \in \mathcal{T}$  non marcato do
    marca( $t$ )
    for each  $\alpha \in \mathcal{L}$  do
         $r \leftarrow \epsilon\text{-clos}(\text{mossa}(t, \alpha))$ 
        if  $r \notin \mathcal{T}$  then
             $\mathcal{T} \leftarrow \mathcal{T} \cup \{r\}$ 
        end if
         $\delta(t, \alpha) \leftarrow r$  ▷ Denota che la  $\delta$  del DFA con input  $t$  ed  $\alpha$  darà output  $r$ 
    end for
end while

```

Si noti che x , \mathcal{T} e δ saranno rispettivamente lo stato iniziale, l'insieme degli stati e la funzione di transizione del DFA corrispondente, \mathcal{F} sarà invece l'insieme di tutti i $t \in \mathcal{T}$ che al loro interno contengono almeno uno stato finale dell'NFA di partenza mentre \mathcal{L} rimane invariato. Quindi il DFA ottenuto in output sarà $D = \langle \mathcal{T}, x, \mathcal{F}, \mathcal{L}, \delta \rangle$.

2.1.1 Minimizzazione

Nell'ambito della teoria degli automi esistono una serie di operazioni e trasformazioni che è possibile effettuare, un esempio può essere la composizione di più automi, tuttavia nel nostro caso poniamo particolare riguardo sulla minimizzazione. Capita spesso infatti che un automa abbia un numero di stati maggiore del necessario e che alcuni di questi stati siano equivalenti tra loro (e dunque duplicati). Attraverso la minimizzazione è possibile *fondere* insieme questi stati tra loro ottenendo infine un automa più snello (in numero di stati e transizioni) e più facile da comprendere. Si noti questo problema degli stati duplicati non sorge solo dalla progettazione umana ma può anche essere un *side effect* di algoritmi come quello di Costruzione per sottoinsiemi mostrato sopra.

L'algoritmo più conosciuto per minimizzare un automa è detto *Algoritmo di Riem-pimento a Scala* e, di seguito, vedremo il suo funzionamento. Tuttavia occorre fare un'importante premessa prima di introdurre l'algoritmo, il funzionamento dello stesso è legato al fatto che la funzione di transizione δ sia definita su ogni $\alpha \in \mathcal{L}$, la letteratura distingue gli automi *incompleti*, che non verificano questa condizione, da quelli *completi*. Negli automi incompleti la funzione di transizione è parziale e dunque sorgono dei problemi nel momento in cui cerchiamo di minimizzarli, una soluzione molto semplice è quella di usare uno *stato di errore* (detto anche *stato pozzo*). Essenzialmente si va a completare la funzione di transizione nei casi mancanti (non definiti) con una transizione

verso questo stato d'errore, allo stesso tempo tutte le transizioni uscenti da questo stato di errore tornano sullo stesso ($\forall_{\alpha \in \mathcal{L}} \delta(E, \alpha) = E$) il nome di stato di pozzo deriva infatti dal fatto che una volta raggiunto non e' possibile uscirne.

L'intuizione alla base dell'algoritmo di riempimento a scala e' la seguente, valutiamo le singole coppie (p, q) con $p, q \in \mathcal{S}$ e cerchiamo un $\alpha \in \mathcal{L}$ tale che lo stato p si comporti diversamente rispetto allo stato q, questo ci permette di dimostrare che p e q non sono equivalenti e dunque non hanno ragione di essere fusi insieme. Alla fine dell'esecuzione tutte le coppie di stati che non saranno distinte tra loro indicheranno degli stati equivalenti.

L'algoritmo di Riempimento della Tabella a Scala e' definito come segue:

Algorithm 2.2 Riempimento della Tabella a Scala

```

Inizializza la tabella a scala con le coppie (p,q)
Marca le coppie (x,y) con marca  $x_0$  con  $x \in \mathcal{F}$  e  $y \notin \mathcal{F}$ 
while  $\exists$  almeno un marchio  $x_i$  all'iterazione i do
    if  $\exists \alpha \in \mathcal{L}, \exists p, q \in \mathcal{S}$  tale che  $\delta(p, \alpha) \neq \delta(q, \alpha)$  then
        Marca (p, q) con marca  $x_i$ 
    end if
    Considera all'iterazione seguente solo gli stati non marcati
end while

```

2.1.2 Esempi

Per concludere questa sezione mostriamo di seguito un esempio dei vari concetti mostrati in questa sezione. Il seguente è un NFA N un grado di riconoscere la Regular Expression $(a|b)^*ba$:




Figura 2.1: Un possibile NFA che riconosce la RegEx $(a|b)^*ba$

Si noti che questo è solo un *possibile* NFA in grado di riconoscere il linguaggio dato ma ne esistono infiniti altri ad equivalenti ad esso. Vediamo ora invece il DFA D, equivalente ad N, calcolato tramite l'algoritmo di *Costruzione per sottoinsiemi*

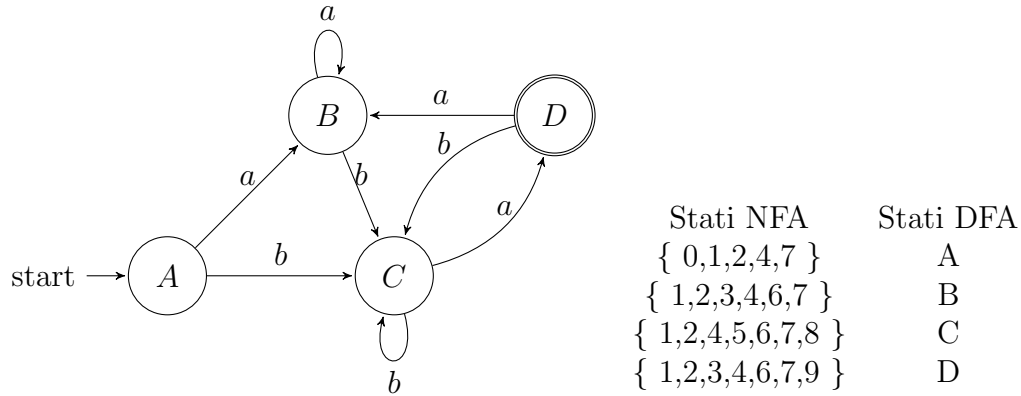


Figura 2.2: Il DFA equivalente a quello in figura 2.1

Ora andiamo a minimizzare il DFA ottenuto precedentemente rimuovendo gli stati equivalenti tramite l'algoritmo di *Riempimento della Tabella a Scala*




Figura 2.3: Il DFA minimizzato ottenuto da quello in figura 2.2

2.2 Choreography Automata

Passiamo ora alla definizione dei *Choreography Automata* (CA); iniziamo diversificando la nozione di *Choreographies* e *Choreography Automata* il primo è un modello logico che permette di specificare le interazioni tra più attori (siano essi processi, programmi, etc.) all'interno di un sistema (concorrente nel nostro caso) mentre i secondi sono invece sono inecce un'*implementazione* possibile per questo modello. In questo caso noi stiamo scegliendo di implementare le Choreographies tramite degli Automi a Stati Finiti ma questo non esclude altre possibili implementazioni equivalenti alla nostra.

Per prima cosa ricordiamo che le Choreographies hanno due tipologie di *view* possibili:

- **Global View:** Che descrive il comportamento dei *partecipanti* "as a whole" specificando anche come questi interagiscano tra loro.
- **Local View:** Che descrive il comportamento di un singolo partecipante in *isolamento* rispetto agli altri.

La *scelta implementativa* di utilizzare gli FSA è dovuta al fatto che gli stessi, oltre ad essere semplici ma espressivi anche per i meno esperti, permettono di utilizzare loop "nested" e "entangled" e permettono di sfruttare in maniera molto conveniente i risultati e le nozioni descritti in precedenza. I Choreography Automata sono dunque dei *casi particolari* di automi a stati finiti in cui le transizioni specificano le interazioni tra i vari partecipanti della coreografia.

Un esempio di Choreography Automata è visibile nella figura sottostante, la sintassi delle label sulle transizioni è la seguente: *sender*→*receiver*:*message*.




Figura 2.4: Un esempio di Choreography Automata

In questo caso sono rappresentate le interazioni tra gli attori A,B e C, in particolare: A inizia la comunicazione mandando un messaggio *tic* a B, B (dopo aver ricevuto tale messaggio) invia a sua volta *count* a C ed infine C risponde ad A con messaggio *toc*.

Definition 2.5 (Choreography Automata) *Un Choreography Automata (c-automata) è un ϵ -free FSA con un insieme di label $\mathcal{L}_{int} = \{A \rightarrow B : m \mid A \neq B \in \mathcal{P}, m \in \mathcal{M}\}$ dove:*

- \mathcal{P} è l'insieme dei partecipanti (per esempio A, B, ecc)
- \mathcal{M} è l'insieme dei messaggi che possono essere scambiati (m, n, ecc)

Remark 2.5.1 *Anche se nella definizione non sono ammesse ϵ -transizioni una variante non deterministica rimane sempre possibile, come vedremo anche più avanti in questo lavoro, ma si tende ad evitare per avere delle composizioni tra automi più corrette.*

2.2.1 CFSM e Local Views

Ora che abbiamo una definizione formale del Choreography Automata, possiamo concentrarci sull'estrapolazione delle varie view locali a partire dallo stesso. Ricordiamo che le view locali descrivono il comportamento di un singolo partecipante all'interno della

coreografia e che sono ottenute attraverso un'operazione di *proiezione* applicata all'intera coreografia (la view globale). Prima di definire però questa operazione di proiezione serve introdurre il concetto di *Communicating Finite-State Machine (CFSM)*, come il nome suggerisce questo è sempre un modello basato su automi a stati finiti usato specificatamente per la descrizione delle local views. La principale differenza rispetto ai CHoreography Automata sta nel fatto che le label sono *direzionali*, ovvero possono essere del tipo "A B ? m" o "A B ! m" per indicare che A riceve (rispettivamente invia) un messaggio m a B.

Definition 2.6 (Communicating Finite-State Machine) *Una Communicating Finite State Machine (CFSM) è un FSA C con insieme di labels:*

$$\mathcal{L}_{act} = \{A B ! m, A B ? m \mid A, B \in \mathcal{P}, m \in \mathcal{M}\}$$

dove \mathcal{P} e \mathcal{M} sono definiti come in precedenza.

Dunque il *soggetto* di un'azione in input "A B ? m" è A, lo stesso vale per l'azione di output "A B ! m", indichiamo quindi con M_a la CFSM con cui ha tutte e solo le transizioni con soggetto A. Si noti che esiste ed è possibile definire formalmente una funzione *system* che assegna ad ogni partecipante $p \in \mathcal{P}$ la sua relativa CFSM M_p .

Ora che abbiamo introdotto tutti i concetti necessari possiamo definire di seguito l'operazione di *Proiezione* su Choreography Automata.

Definition 2.7 (Proiezione) *La proiezione su A di una transizione $t = s \xrightarrow{a} s_2$ di un Choreography Automata, scritta $t \downarrow_A$ è definita come:*

$$t \downarrow_A = \begin{cases} s \xrightarrow{A C ! m} s' & \text{se } a = B \rightarrow C : m \wedge B = A \\ s \xrightarrow{B A ? m} s' & \text{se } a = B \rightarrow C : m \wedge C = A \\ s \xrightarrow{\epsilon} s' & \text{se } a = B \rightarrow C : m \wedge B, C \neq A \\ s \xrightarrow{\epsilon} s' & \text{se } a = \epsilon \end{cases}$$

La proiezione di un CA = $\langle \mathcal{S}, s_0, \mathcal{L}_{int}, \delta \rangle$ sul partecipante $p \in \mathcal{P}$, denotata con $CA \downarrow_p$ è ottenuta ricavando in primis l'automa intermedio:

$$A_p = \langle \mathcal{S}, s_0, \mathcal{L}_{act}, \{s \xrightarrow{t \downarrow_p} s' \mid s \xrightarrow{t} s' \in \delta\} \rangle$$

tuttavia, come possiamo vedere nella definizione sopra, questo automa intermedio è deterministico. E' dunque necessario rimuovere le eventuali ϵ -transizioni, ottenendone una versione deterministica e successivamente minimizzare quest'ultima, entrambe le operazioni sono le medesime definite rispettivamente in 2.1 e 2.2

Capitolo 3

Adattazioni e modifiche

TODO

Capitolo 4

Tecnologie utilizzate

TODO

Capitolo 5

Descrizione del tool

TODO

Capitolo 6

Conclusioni e lavori futuri

TODO